




激光雷达SLAM建图





CONTENTS

目录

- 1 视觉SLAM
- 2 激光雷达
- 3 激光雷达SLAM



教学目标和重难点

➤ 教学目标

1. 了解激光雷达的基础知识

重点

2. 视觉SLAM基本原理

难点

3. 掌握自动驾驶汽车SLAM建图过程

难点



① 视觉SLAM

- ◆同时定位与建图(SLAM)技术已广泛应用于各类自主移动平台中，其中视觉SLAM和激光雷达SLAM是两种主要的SLAM技术方案。
- ◆SLAM属于机器人领域的技术，顾名思义，它的目的是实现对传感器载体的“定位”和对环境的“建图”。它属于小范围的局部定位，卫星导航属于大范围的全局定位，二者可互补，实现无缝切换的定位。
- ◆SLAM最早于20世纪80年代被提出，早期的SLAM系统主要是基于单线激光雷达传感器构建的，且仅适用于在二维平面中运动的载体。随着激光雷达技术的发展，基于激光雷达的3D SLAM系统得到迅速发展。
- ◆目前，性能较好的激光雷达可以实现百米外厘米级的测距精度，支撑了一系列高精度SLAM应用场景。

➤ 从全局定位到局部定位


- ◆全局定位则通过测量用户的绝对位置来定位，定位的精度较高，并且可以用来修正局部定位的定位误差。局部定位则通过测量相对于用户初始位置的距离和方向来确定当前的位姿，但随着时间的推移会造成定位的累积误差。
- ◆基于全球卫星定位系统（GPS，北斗，格洛纳斯和伽利略）的卫星定位是全局定位方式，它们可以通过四颗以上的卫星观测告诉用户现在“在地球的哪里”，定位精度在5-10m，高精度单点定位精度可达厘米级。但是由于到达地面的卫星信号存在遮挡、干扰以及欺骗等问题，这造成卫星定位精度不足以满足实际应用需求。因此，卫星导航常常与惯性导航系统结合成为组合导航系统，能在卫星信号不可靠的区域提供稳定的全局定位。

➤ 从全局定位到局部定位

- ◆ 在GNSS拒止的场景，如停车场、交错高架路以及室内环境等卫星信号差的场景，惯导的累积误差无法消除, 惯导组合导航的可靠性下降。因此，引入一些高精度的局部定位方式十分有必要，而SLAM就是其中一种可行性高的方案。
- ◆ SLAM通常可使用的传感器包括激光雷达、单目相机、双目相机和RGB-D相机等，其中相机的成本相对低、结构简单。我们将基于各类相机的SLAM技术称为“视觉SLAM”，它可以通过相机对环境的观测告诉我们“在小范围环境的哪里”。




◆视觉SLAM通过相机的观测（图像）去估计相机的位置和姿态，并同时构建环境地图，其主要的定位原理为多视图几何原理[1]，如下图所示。通过相机在三个不同时刻对环境“路标” X_1 、 X_2 和 X_3 的观测，估计出相机在三个时刻（ C_1 ， C_2 ， C_3 ）的位置和姿态—定位，并还原出“路标”的位置—建图。该过程本质是融合“先验”和“观测”的最大后验估计，但是由于仅有相机的观测，而无先验自主运动信息，因此最终退化为最大似然估计。





视觉SLAM基本原理

◆经典的视觉SLAM框架可以简化为4个模块，框架如下图所示。






视觉SLAM基本原理

- ◆首先相机获取环境图像，送入前端视觉里程计。
- ◆前端视觉里程计估计相邻时刻相机的运动，以及局部地图，由于估计相邻时刻的运动，因此存在累积误差。
- ◆后端优化接受多个时刻视觉里程计估计的相机位姿，以及回环检测的信息，对它们进行优化，得到尺度一致的位姿和地图。
- ◆回环检测判断相机是否到达过先前经过的位置，如果检测到回环，会将回环信息传给后端优化进行处理，消除视觉里程计存在的累积误差。
- ◆建图则将传感器获取的序列图像基于估计的相机位姿标校之后，融合起来构建符合要求的环境地图，如点云地图和拓扑地图等。

- ◆DSO运行实例：红色线条为定位轨迹，半稠密点云为地图





视觉SLAM基本原理

- ◆ 视觉SLAM根据特征匹配过程的不同可以分为直接法和特征点法。直接法将特征匹配和位姿估计紧耦合在一起，可以降低计算误差，但对相机曝光很敏感。
- ◆ 直接法稀疏里程计（direct sparse odometry, DSO）是一个经典的直接法视觉里程计，它将光度误差和几何约束联合优化，这提高了系统在运动过快及特征较弱环境下的鲁棒性。
- ◆ 特征点法可以提供较长时间的特征关联，实现回环检测，并且对相机曝光参数相对不敏感。
- ◆ ORB-SLAM系列是特征点法SLAM的巅峰之作，其最大的特点是在追踪线程和建图线程的基础上将回环检测线程加入整个系统，有效地降低了累积误差，同时三线程的基础框架也广泛地被后续学者们认同和采用。
- ◆ 但是在暗光，弱纹理和高速运动等情况下，常规相机不能捕捉到有效的环境特征，导致视觉SLAM的特征提取和匹配受到非常大的影响，定位精度差，甚至定位失败。因此，它主要的发展方向是鲁棒化。

◆视觉SLAM的鲁棒化主要通过融入其他信息源实现，包括更高级的几何特征，其他传感器信息和语义信息，多源融合是未来的大趋势。

- ✓ **多特征融合**：点特征在视觉SLAM中使用最广泛,然而在走廊和办公室等环境中有着大量白墙等弱纹理区域,由于无法提取足够的特征点,基于点特征的方法不再适用,但是上述环境中的直线、曲线、平面、曲面和立方体等多维几何特征却十分丰富,将这些特征结合可进行更稳定的定位与建图。
- ✓ **多传感器融合**：基于单一传感器的定位方案都有优劣: 视觉SLAM可获取语义信息，但依赖场景纹理特征；IMU定位可测量自主运动，但有严重的累积误差；激光SLAM可获取环境稠密深度，但依赖于场景几何特征，且设备获取深度的精度和范围受限于设备的成本和功耗。因此，需要将不同传感器数据融合起来取长补短实现更强的鲁棒性和更好的精度，满足智能机器人和自动驾驶的需求。


◆视觉SLAM的鲁棒化主要通过融入其他信息源实现，包括更高级的几何特征，其他传感器信息和语义信息，多源融合是未来的大趋势。

- ✓ **与场景理解融合**：在大雾、暗光和快速运动下,相机成像质量差，几何特征提取和匹配不稳定,大大降低闭环检测的准确性。而语义信息是长期稳定的特征,在表征环境拥有极强的稳定性，但语义信息的匹配较为粗糙，无法实现精确定位。因此,将语义信息融合到视觉SLAM系统中,可以优势互补，增强视觉SLAM系统的鲁棒性。




② 激光雷达

激光雷达，也称光学雷达（Light Detection And Ranging, LiDAR）是激光探测与测距系统的简称。它通过向物体发射激光并捕获移动时间来测定与目标物体之间的传播距离，分析目标物体表面的反射能量大小、反射波谱的幅度、频率和相位等信息，从而呈现出目标物精确的三维结构信息。



激光雷达结构


- ◆ 基于图优化的SLAM方案考虑了载体移动过程中全部的位姿状态和环境观测信息，用节点和边形成的图来表示一系列的移动机器人位姿和约束，建立和维护关联数据。相较于早期基于滤波器的SLAM方法，图优化SLAM通常可以得出全局一致性更好的地图，且在相同计算量的前提下，其求解速度也已经超过滤波器方法，是目前SLAM领域内的主流方法，也是三维激光SLAM采取的主要方案。




基于图优化的激光SLAM框架

- ◆ 基于图优化的SLAM方案可以分为扫描匹配、闭环检测、后端优化、点云地图存储表示四个部分。
- ◆ 扫描匹配利用激光雷达、惯性测量单元(IMU)及编码器等传感器数据进行扫描匹配，利用相邻帧之间的关系估计当前帧的运动姿态，得到短时间内的相对位姿和地图，考虑局部数据关联问题；
- ◆ 由于长时间的增量式扫描匹配会不可避免地造成误差累积，闭环检测通过比较当前帧与历史关键帧来优化位姿，检查匹配确立节点间的约束关系，减少全局地图的漂移误差，考虑全局数据关联问题。
- ◆ 从基于图优化的表示形式来看，扫描匹配和闭环检测都是为了根据观测信息建立图的节点以及节点间的约束，即完成图的构建，可将两者一起划分为图优化SLAM的前端部分。


- ◆ 由于系统参数误差、观测噪声以及匹配误差的存在，通过前端模块所构建的位姿图一致性较差，且通常情况下构建图的边与边的约束存在“冲突”。
- ◆ 理想情况下，构成闭环的帧间匹配相对变换矩阵乘积应为单位矩阵，但实际工程中通过前端得到的相对变换矩阵一般是达不到此结果的。
- ◆ 因此，在后端优化部分对前端构建的图信息进行非线性优化，取得尽量满足所有约束关系的最优解，最后输出姿态估计结果和全局点云地图，这一部分也被称为SLAM后端，与SLAM前端共同组成整个图优化SLAM框架。




点云地图



八叉树地图



稀疏特征点地图



语义地图

激光雷达点云具有局部稀疏性、数据量大、动态对象引起噪声以及几何退化环境不敏感的特征，这也成为了基于激光点云的SLAM研究中的难点。

- 局部稀疏。与图像匹配问题相比，点云的稀疏性使得从源点云和目标点云中找到两个精确匹配点通常是不可行的，而且激光扫描仪从不同角度观察到的同一物体的外观差异很大，增加了特征提取的难度。在理想情况下激光里程计的输出结果可直接导出使用，其精度直接影响最后的结果，因此找到一种高效通用的方法实现激光和惯导数据的紧耦合并提升精度仍是未来的研究重点。
- 算法实时性。由于激光扫描仪每秒会产生数百万个点，需要高效的算法和强大的计算单元，对于算法的实时性有着较高的要求。

激光雷达点云具有局部稀疏性、数据量大、动态对象引起噪声以及几何退化环境不敏感的特征，这也成为了基于激光点云的SLAM研究中的难点。

- 动态点云。动态点云是指环境中存在行人、车辆等动态物体的干扰，传统激光SLAM的点云配准基于静态假设，实际中如果动态点比例过高，就会造成轨迹精度下降，并且会在所构成的点云地图中形成“鬼影”，十分不利于后续的定位导航。因此如何在高速运动场景中实现鲁棒性的位姿估计亦是研究的热点之一。
- 退化环境。退化环境在激光SLAM中指的是场景几何结构上存在高度相似性，包括长隧道、长走廊这些典型场景，以及三维激光slam面对的视野开阔而缺乏几何特征点的环境。在这些场景中，激光雷达观测到的数据会在某一维度呈现高度的相似性，以致点云配准结果收敛至错误位姿，严重影响SLAM的整体性能。



③ 激光雷达SLAM

2.0小车中使用的是ROS中的gmapping模块来实现建图过程，gmapping算法是一种基于激光雷达的机器人定位与地图构建方法。它采用栅格地图（gridmap）来表示室内环境，利用激光雷达数据，以及机器人运动信息，来实现机器人位置估计和环境地图构建。

➤ SLAM问题的概率描述

首先，一个完整的SLAM问题是在给定传感器数据的情况下，同时进行机器人位姿和地图的估计的问题。然而，现实的情况是这样的，如果需要得到一个精确的位姿需要与地图进行匹配，如果需要得到一个好的地图需要有精确的位姿才能做到，显然这是一个相互矛盾的问题。

概率描述如下式：

$$p(x_{1:t}, m | u_{1:t}, z_{1:t})$$

显然是一个条件联合概率分布，用在移动机器人从开机到t时刻一系列传感器测量数据 $z_{1:t}$ （这里当然是/scan）以及一系列控制数据 $u_{1:t}$ （这里认为是/odom）的条件下，同时对地图 m 、机器人轨迹状态 $x_{1:t}$ 进行的估计来描述SLAM问题。

➤ SLAM问题分解

FastSLAM算法独辟蹊径，采用RBPF方法，将SLAM算法分解成两个问题。一个是机器人定位问题，另一个是已知机器人位姿进行地图构建的问题。分解过程的公式推导如下式：

$$\begin{aligned} & p(x_{1:t}, m | u_{1:t}, z_{1:t}) \\ & \quad \downarrow \text{通过条件联合概率分布化简: } p(A, B | Z) = P(A | Z)P(B | A, Z) \\ & = p(x_{1:t} | u_{1:t}, z_{1:t}) p(m | x_{1:t}, u_{1:t}, z_{1:t}) \\ & \quad \downarrow u_{1:t} \text{与} m \text{无关, 可直接化简, 因为有轨迹+测量即可闭式计算地图} \\ & = p(x_{1:t} | u_{1:t}, z_{1:t}) p(m | x_{1:t}, z_{1:t}) \end{aligned} \quad (3.2)$$

其中 $p(x_{1:t} | u_{1:t}, z_{1:t})$ 表示估计机器人的轨迹， $p(m | x_{1:t}, z_{1:t})$ 表示在已知机器人轨迹和传感器观测数据情况下，进行地图构建的闭式计算。这样SLAM问题就分解成两个问题。其中已知机器人位姿的地图构建是个简单问题，所以机器人位姿的估计是一个重点问题。

➤ 机器人轨迹增量估计分解

FastSLAM算法采用粒子滤波来估计机器人的位姿，并且为每一个粒子构建一个地图。所以，每一个粒子都包含了机器人的轨迹和对应的环境地图。现在我们着重研究一下 $p(x_{1:t} | u_{1:t}, z_{1:t})$ 估计机器人的轨迹。通过使用贝叶斯准则对 $p(x_{1:t} | u_{1:t}, z_{1:t})$ 进行公式推导如式：

$$\begin{aligned} p(x_{1:t} | u_{1:t}, z_{1:t}) &= (x_{1:t} | z_t, u_{1:t}, z_{1:t-1}) \longrightarrow \text{转换, 因为要寻找 } z_t \text{ 与 } x_t \text{ 的关系} \\ &\downarrow \text{根据条件贝叶斯公式化简} \\ &= \eta p(z_t | x_{1:t}, u_{1:t}, z_{1:t-1}) p(x_{1:t} | u_{1:t}, z_{1:t-1}) \\ &\downarrow \text{从理论上讲, } x_t \text{ 足以预测 } z_t, z_t \text{ 与其他无关, 可以直接约减} \\ &= \eta p(z_t | x_t) p(x_{1:t} | u_{1:t}, z_{1:t-1}) \\ &\downarrow \text{根据条件联合概率公式化简 并且, } p(x_{1:t}) = p(x_t, x_{1:t-1}) \\ &= \eta p(z_t | x_t) p(x_t | x_{1:t-1}, u_{1:t}, z_{1:t-1}) p(x_{1:t-1} | u_{1:t}, z_{1:t-1}) \\ &\downarrow \text{从理论上讲, } x_t \text{ 只与 } x_{t-1} \text{ 和 } u_t \text{ 有关, } x_t \text{ 与其他无关, 可以直接约减} \\ &= \eta p(z_t | x_t) p(x_t | x_{t-1}, u_t) p(x_{1:t-1} | u_{1:t-1}, z_{1:t-1}) \end{aligned} \quad (3.3)$$

➤ 机器人轨迹增量估计分解

经过上面的公式推导，这里将机器人轨迹估计转化成增量估计的问题，用 $p(x_{1:t-1} | u_{1:t-1}, z_{1:t-1})$ 表示上一时刻的机器人轨迹，用上一时刻的粒子群表示。每一个粒子都用运动学模型 $p(x_t | x_{t-1}, u_t)$ 进行状态传播，这样就得到每个粒子对应的预测轨迹。对于每一个传播之后的粒子，用观测模型 $p(z_t | x_t)$ 进行权重计算归一化处理，这样就得到该时刻的机器人轨迹。之后根据估计的轨迹以及观测数据进行地图构建。

推导公式参考：

$$p(x|y,z) = \frac{p(y|x,z)p(x|z)}{p(y|z)} = \eta p(y|x,z)p(x|z) \quad \text{条件贝叶斯公式}$$

$$p(x,y|z) = p(x|y,z)p(y|z) \quad \text{条件联合概率公式}$$

2.0小车中使用的是ROS中的gmapping模块来实现建图过程，gmapping算法是一种基于激光雷达的机器人定位与地图构建方法。它采用栅格地图（gridmap）来表示室内环境，利用激光雷达数据，以及机器人运动信息，来实现机器人位置估计和环境地图构建。

➤ Gmapping算法工作流程

- (1) 激光雷达传感器对周围环境进行扫描，将激光数据转换成2D栅格地图。
- (2) 采用概率滤波算法（Probabilistic Filtering），使用当前激光数据和机器人的位姿信息，估计机器人的位姿。
- (3) 使用激光数据和机器人位姿信息，更新栅格地图中的障碍物点和每个栅格的概率值，从而更新地图。
- (4) 将构建的栅格地图，保存成文件。

- ◆ SLAM问题被分解成了两个问题，**机器人轨迹估计问题和已知机器人轨迹的地图构建问题**。
- ◆ FastSLAM算法中的机器人轨迹估计问题使用的粒子滤波方法。由于使用的是粒子滤波，将不可避免的带来两个问题：
 - 第一个问题，当环境大或者机器人里程计误差大时，需要更多的粒子才能得到较好的估计，这时将造成内存爆炸；
 - 第二个问题，粒子滤波避免不了使用重采样，以确保当前粒子的有效性，然而重采样带来的问题就是粒子耗散，粒子多样性的丢失。

由于这两个问题出现，导致FastSLAM算法理论上可行实际上却不能实现。针对以上问题gmapping提出了两种针对性的解决方法。也就是说gmapping是基于FastSLAM算法将RBPF方法变成了现实。

➤ 降低粒子质量

- ◆ 问题由来：每一个粒子都包含自己的栅格地图，对于一个稍微大一点的环境来说，每一个粒子都会占用比较大的内存。如果机器人里程计的误差比较大，即proposal分布（提议分布）跟实际分布相差较大，则需要较多的粒子才能比较好的表示机器人位姿的估计，这样将会造成内存爆炸。
- ◆ 目的：通过降低粒子数量的方法大幅度缓解内存爆炸。
- ◆ 分析：里程计的概率模型比较平滑，是一个比较大的范围，如果对整个范围采样将需要很多的粒子，如果能找到一个位姿优值，在其周围进行小范围采样，这样不就可以降低粒子数量了嘛。

➤ 降低粒子质量


- ◆ 方法一：直接采用极大似然估计的方式，根据粒子的位姿的预测分布和与地图的匹配程度，通过扫描匹配找到粒子的最优位姿参数，就用该位姿参数，直接当做新粒子的位姿。如下图所示，从普通的proposal分布采样替换为用极大似然估计提升采样的质量。这也就是gmapping算法中的做法。

$$x_t^i \sim p(x_t | u_t, x_{t-1}^i) \quad \longrightarrow \quad x_t^i = \arg \max_{x_t} \{p(z_t | x_t, m) p(x_t | u_t, x_{t-1}^i)\}$$

➤ 降低粒子质量

◆ 方法二：gmapping算法通过最近一帧的观测（scan），把proposal分布限制在一个狭小的有效区域。然后在正常的对proposal分布进行采样。该方法是gmapping论文中详细描述的方法。

◆ 假设



激光雷达匹配比里程计的测量精确很多，从分布上来说，激光雷达匹配的方差要比里程计模型的方差小很多

➤ 降低粒子质量

- ◆ 如果proposal分布用激光匹配来表示，则可以把采样范围限制在一个比较小的区域，因此可以用更少的粒子即覆盖了机器人位姿的概率分布。也就是说将proposal分布从里程计的观测模型变换到了激光雷达观测模型。具体公式推导如下所示：

$$\begin{aligned}
 & \text{用观测模型为预测模型限制一个密集区域代替预测分布} \\
 & \text{预测分布也叫prosoal分布} \quad p(x_t | x_{t-1}, u_t) \rightarrow p(x_t | x_{t-1}, u_t, z_t, m) \quad \text{加入地图m和观测} z_t \\
 & p(x_t | x_{t-1}, u_t, z_t, m) = p(x_t | z_t, u_t, x_{t-1}, m) \rightarrow \text{替换} \\
 & \downarrow \text{根据条件贝叶斯公式化简} \\
 & = \eta p(z_t | x_t, u_t, x_{t-1}, m) p(x_t | x_{t-1}, u_t, m) \\
 & \downarrow \text{将无关项约减掉，简化公式} \\
 & = \eta p(z_t | x_t, m) p(x_t | x_{t-1}, u_t) \\
 & \downarrow \text{由于} x_t \text{属于尖峰区域，预测分为可视常数化简} \\
 & = \eta p(z_t | x_t, m), x_t \in L^{(i)}
 \end{aligned}$$

从上图可以看到激光雷达观测模型方差较小，假设其服从高斯分布，使用多元正态分布公式即可进行计算，于是求解高斯分布是下面需要做的。

➤ 降低粒子质量

- ◆ 同方法一，首先通过极大似然估计找到局部极值 x_t ，认为该局部极值距离高斯分布的均值比较近，于是在位姿 x_t 附近取了 k 个位姿；对 k 个位姿进行打分（位姿匹配），这样我们就具有 k 个位姿，以及它们与地图匹配的得分；我们又假设它们服从高斯分布，计算出它们的均值和方差之后，即可使用多元正态分布，对机器人位姿的估计进行概率计算。矢量均值和协方差的计算。具体如下式(3.4) (3.5)

矢量均值
$$\mu = \frac{1}{\eta} \sum_{j=1}^K x_j p(z_t | x_j, m) \quad (3.4)$$

协方差
$$\Sigma = \frac{1}{\eta} \sum_{j=1}^K (x_j - u)(x_j - u)^T p(z_t | x_j, m) \quad (3.5)$$

➤ 降低粒子质量

◆ 多元正态分布公式如下，可以根据均值和协方差，直接计算得出后验概率。

$$p(x) = \det(2\pi\Sigma)^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right\}$$

当然，这里不仅要计算每一个粒子的轨迹的后验概率，还要为每一个粒子计算权重，这里对权重具体的计算方式就不做描述了。

➤ 缓解粒子耗散

- ◆ 问题由来：gmapping算法采用粒子滤波算法对移动机器人轨迹进行估计，必然少不了粒子重采样的过程。随着采样次数的增多，会出现所有粒子都从一个粒子复制而来，这样粒子的多样性就完全丧失了。
- ◆ 目的：缓解粒子耗散
- ◆ 分析：gmapping算法从算法原理上使用粒子滤波，不可避免的要进行粒子重采样，所以，问题实实在在的存在，不能解决，只能从减少重采样的思路走。

➤ 缓解粒子耗散

- ◆ 方法：gmapping提出选择性重采样的方法，根据所有粒子自身权重的离散程度（也就是权重方差）来决定是否进行粒子重采样的操作。于是就出现了式（3.7），当 N_{eff} 小于某个阈值，说明粒子差异性过大，进行重采样，否则，不进行。

$$N_{eff} = \frac{1}{\sum (w^i)^2} \quad (3.7)$$



Thank You

AI改变生活